

# Technická zpráva k semestrální práci z předmětu MI-ROZ

## Textural Features Corresponding to Visual Perception

Tomáš Duda  
dudatom2@fit.cvut.cz

25. prosince 2015

### Abstrakt

Semestrální práce se zabývá implementací texturálních příznaků převzatých z článku od Hideyuki Tamury, jež jsou inspirovány způsobem, jakým textury vnímají lidé. Výpočet příznaků je modifikován do podoby, aby šel využit pro nesupervizovanou segmentaci textur v barevných obrázcích. Implementované příznaky byly testovány na datasetu 80 obrázků poskytnutém vyučujícím předmětu. V rámci ladění semestrální práce byly testovány různé nastavení extrakce příznaků. V běhu s nejlepším výsledkem dosáhla implementace správnosti segmentace 28,75.

## 1 Úvod

Cílem semestrální práce bylo implementovat sadu příznaků z vybraného odborného článku, které by abstrahovali informaci o texturách v zadaných obrázcích, jež by mohla posloužit jako vstup pro nesupervizovaný shlukovací algoritmus, který rozdělí obrázek na jednotlivé segmenty.

V rámci své semestrální práce jsem se rozhodnul implementovat takzvané Tamurovy příznaky, [1].

## 2 Segmenter

V této sekci uvádím jednotlivé příznaky a popisuji způsob implementace své semestrální práce.

### 2.1 Příznaky

V citovaném článku autoři navrhují celkem 6 příznaků. Hlavní myšlenkou těchto příznaků je simulovat způsob, jakým vnímají textury lidé. Popsali proto způsob, jakým je možné exaktně popsat 6 základních vlastností textur, kterých si lidé všímají. Jako hlavní míru úspěšnosti své metody autoři volili korelaci výstupů navrženého algoritmu s výsledky psychologického experimentu, při kterém předkládali lidem dvojice obrázků rozdílných textur a požadovali, aby testovaná osoba vyřkla, který obrázek je zrnitější, více kontrastní či pravidelnější.

Ze zmíněných experimentů autorům vyšlo, že algoritmus se nejlépe shoduje s lidským vnímáním v případě prvních třech příznaků, kterými jsou coarseness, contrast a directionality. Z toho důvodu jsem v průběhu implementace testoval i různé kombinace příznaků a sledoval rozdíly ve výsledcích testovacích běhů. Výstup z těchto měření je uveden v sekci výsledky.

Níže uvádím podrobnější popis jednotlivých příznaků a náznak způsobu jejich výpočtu.

#### Coarseness (zrnitost)

Hodnota toho příznaku reprezentuje velikost zrn v obrázku. V rámci jeho výpočtu v obrázku zkoumá intenzita barvy v různých velkých okolích a hledá se tak velké okolí, kde nastávají v intenzitě barvy největší změny.

#### Contrast (kontrast)

Reprezentuje rozptyl jasových hodnot v obrázku. Pro výpočet se využívají statistické ukazatele nad souborem jasových hodnot v obrázku.

#### Directionality (směrovitost)

Hodnoty příznaku nesou informaci o přítomnosti směrové orientace v obrázku. V rámci výpočtu se pomocí konvolučních masek stanoví derivace ve vertikálním a horizontálním směru. Vypočítané hodnoty jsou dále chápány jako gradienty. Ze směrů gradientů se sestaví histogram a výslednou hodnotou příznaku je suma rozptylů v okolích vrcholů histogramu.

#### Linelikeness (přímkovitost)

Příznak reprezentuje, zda je textura sestavena z jednotlivých čar. Hodnota příznaku se určuje z kookurenční matice směrů v obrázku. Sémantika hodnoty v kookurenční matici je vizualizována na obrázku 1. Jde o relativní frekvenci, s jakou se v určité vzdálenosti objevují v obrázku gradienty se shodnou orientací. Gradient u každého bodu se opět počítá pomocí poměru konvoluce v kolmých směrech.

#### Regularity (pravidelnost)

Hodnota příznaku nese informaci o pravidelnosti textury. Autoři ji počítají jako rozptyl hodnot prvních 4 příznaků na různých částech obrázku.

#### Roughness (hrubost)

Příznak reprezentuje hrubost textury. Je počítána jako součet prvních 2 příznaků.


#### Implementace příznaků

Jelikož jsem v rámci semestrální práce potřeboval využít příznaky pro segmentaci textur v barevných obrázcích, přizpůsobil jsem tomuto účelu způsob jejich výpočtu.

V citovaném článku autoři testují metodu na obrázcích, ve kterých je zobrazena jediná textura, a proto počítají jednu hodnotu příznaku pro celý obrázek. Z toho důvodu jsem modifikoval výpočet do podoby, kdy počítám hodnotu příznaku pro každý pixel v obrázku, přičemž beru v úvahu jeho okolí.

V rámci implementace jsem zkoušel volit různé velikosti okolí bodů.

V článku autoři pracují s černobílými obrázky. Jelikož vstupem mé implementace byly obrázky barevné, počítám příznaky pro každé spektrum RGB zvlášť. Pro každý bod v každém vstupním obrázku tedy počítám celkem 18 příznaků.



Obrázek 1: Vizualizace sémantiky hodnoty na pozici  $(i, j)$  v kookureční matici. Jde o relativní frekvenci, s jakou se body s velikostí úhlu gradientu rovnou  $i$ , respektive  $j$  (úhly jsou diskretizovány, aby šla matice sestavit) vyskytují ve vzdálenosti  $d$  v obrázku.

## 2.2 Segmentace

Segmentace vstupních obrázků probíhala na základě aplikace shlukovacího algoritmu na matice hodnot příznaků, jež abstrahovali informaci o texturách ve vstupním obrázku. Do procesu segmentace jsem v rámci své semestrální práce nezasahoval.

Způsob segmentace, tedy shlukování s předem známým počtem shluků, ve výsledcích mé práce způsobil občasné problémy, kdy mnou implementované příznaky nerozpoznali v obrázku některou z textur, což způsobilo, že nadbytečný shluk posloužil k rozdělení oblasti s rozpoznanou texturou, která v obrázku zabírala největší plochu na dvě poloviny, ačkoliv toto rozdělení nedává smysl.

## 2.3 Postprocessing

V rámci postprocessingu se nad hodnotami příznaků prováděla normalizace. Tato transformace měla na výsledek kladný vliv, jelikož hodnoty jednotlivých příznaků se mohou řádově lišit. V rámci své semestrální práce jsem neimplementoval nové prvky do postprocessingu.

## 3 Výsledky


Jelikož autoři v článku považují příznaky coarseness, contrast a directionality (v druhé řadě i regularity) za hodnotnější než zbývající, testoval jsem výstup algoritmy na třech různých podmnožinách příznaků. V prvním běhu byly z obrázků extrahovány příznaky coarseness, contrast a directionality, ve druhém běhu byl přidán příznak directionality, v posledním běhu jsem testoval kompletní sadu příznaků. Rovněž jsem algoritmus spouštěl pro dvě rozdílné velikosti okolí bodů, pro které se počítá příznak -  $16 \times 16$  pixelů a  $32 \times 32$  pixelů. Výsledky měření jsou uvedeny v tabulce 3. Ukazují, že 4.–6. příznak nezanášejí do řešení informaci, která by zvyšovala kvalitu segmentace. Rovněž je vidět, že pro větší počet příznaků získáváme lepší výsledky s použitím většího okolí bodu.

Obrázek 2 poukazuje na hlavní nedostatky implementovaného řešení (prezentované obrázky jsou výstupem běhu se všemi 6 příznaky). Na prvním obrázku je vidět výsledek přesegmentování textury. Jednou z možností, jak se tímto problémem potýkat, by bylo zkusit použít větší okolí bodu, pro-

Počet příznaků	CS pro $16 \times 16$	CS pro $32 \times 32$
3	28,75	28,65
4	20,00	20,25
6	24,03	25,81

Tabulka 1: Výsledky měření kvality segmentace pro různé podmnožiny příznaků a různá okolí bodu. CS je správnost segmentace (correct segmentation), tedy jak výstup algoritmu odpovídal stanovené ground truth.

blémem však je prudce narůstající výpočetní náročnost při takové změně. Na druhém obrázku je vidět špatně rozpoznaná hrana mezi texturami. Tuto chybu považuji za důsledek toho, že metoda v původním článku byla určena pro měření vlastností textur v rámci celého obrázku, a algoritmus aplikovaný na jednotlivé body a jejich okolí tudíž produkuje rozdílné hodnoty  $i$  pro přechod mezi texturami (a okolí přechodu) a samotné textury. Třetí obrázek poukazuje na potíže se segmentací obrázků, na nichž jsou textury silně nepravidelné a mají velká zrna (v terminologii implementovaného algoritmu). Eventuálním řešením by opět mohl být výpočet s použitím většího okolí bodu.



Obrázek 2: Příklady chybných výsledků segmentace. Horní řádek: vstupní data (obrázek s několika segmenty). Dolní řádek: výsledná segmentace. První sloupec: ukázka přesegmentování. Druhý sloupec: chybné rozeznání hranice mezi texturami. Třetí sloupec: chybně rozeznané textury s velkými zrna.

## 4 Shrnutí

V rámci semestrální práce jsem nastudoval metodu pro měření vlastností textur, modifikoval ji pro použití na segmentaci textur, implementoval, otestoval možnosti nastavení parametrů algoritmu a provedl měření kvality segmentace. Konečné výsledky považuji s ohledem na fakt, že jde o relativně starou metodu, za kvalitní.

## Reference

- [1] TAMURA, H., MORI, S. a YAMAWAKI, T.. *Textural Features Corresponding to Visual Perception*. IEEE Transactions on Systems, Man, And Cybernetics. Ročník 8. Číslo 6. 1978.